Relazione Tecnica: Analisi Statistica e Predittiva dei Dati sul Diabete

Progetto 8 – Modelli e Metodi di Ottimizzazione Statistica

---

1. Introduzione al Contesto Clinico
    - 1.1 Il Ruolo dell'Insulina e l'Omeostasi Glicemica
    - 1.2 Fisiopatologia: Perché si sviluppa il diabete?
    - 1.3 Classificazione delle Tipologie di Diabete
    - 1.4 Complicanze e Gestione a Lungo Termine
2. Obiettivi del Progetto e Variabili di studio
    - 2.1 Definizione dell'Obiettivo Scientifico
    - 2.2 La Variabile di Risposta: Glicoemoglobina (HbA1c)
    - 2.3 Selezione delle Variabili Esplicative (Predittori)
    - 2.4 Approfondimento su la glicoemoglobina e sul legame con l'indice di massa corporea
3. Selezione delle Variabili e Data Engineering (Python)
    - 3.1 Integrazione dei Flussi di Dati
    - 3.2 Definizione del Dataset Analitico
    - 3.3 Normalizzazione dell'Attività Fisica (LTPA)
    - 3.4 Pulizia dei Dati (Data Cleaning)
    - 3.5 Differenze tra prima e dopo la pulizia
        - 3.5.1 Analisi delle distribuzioni - istogrammi
    - 3.6 Matrice di Correlazione
4. Analisi Statistica e Modellazione (MATLAB)
    - 4.1 Analisi delle Correlazioni
    - 4.2 Regressione Lineare Multipla e la "Trappola del P-Value"
5. Validazione del Modello Predittivo
    - 5.1 Strategia di Suddivisione (Holdout 80/20)
    - 5.2 Valutazione Visiva (Scatter Plot) e Metriche Quantitative
6. Conclusioni

1. Introduzione al Contesto Clinico

Il Diabete Mellito rappresenta una delle principali sfide sanitarie a livello globale, con incidenza e prevalenza in progressivo aumento secondo i dati riportati dalla World Health Organization. Si tratta di una patologia metabolica cronica caratterizzata da iperglicemia persistente, ossia da un'elevata concentrazione di glucosio nel sangue.

1.1 Il Ruolo dell'Insulina e l'Omeostasi Glicemica

Il glucosio è la principale fonte di energia per le cellule del corpo umano. Per essere assorbito dai tessuti, esso necessita dell'intervento dell'**insulina**, un ormone fondamentale secreto dalle cellule β del pancreas. In un organismo sano, il pancreas regola la produzione di insulina in risposta all'assunzione di cibo, garantendo che i livelli di zucchero nel sangue rimangano entro intervalli di sicurezza.

1.2 Fisiopatologia: Perché si sviluppa il diabete?

Il diabete si sviluppa quando il sistema di regolazione insulina–glucosio risulta compromesso. I principali meccanismi fisiopatologici riconducibili alla malattia sono:

- **Deficit di produzione insulinica:** il pancreas non è in grado di produrre quantità adeguate di insulina per soddisfare le esigenze metaboliche dell'organismo.

- **Insulino-resistenza:** i tessuti periferici mostrano una ridotta sensibilità all'azione dell'insulina, ostacolando l'ingresso del glucosio nelle cellule e determinandone l'accumulo nel circolo ematico.

Spesso, nelle forme più comuni della patologia, questi due meccanismi coesistono in misura variabile.

1.3 Classificazione delle Tipologie di Diabete

La letteratura medica distingue diverse forme della patologia, ognuna con caratteristiche e fattori di rischio differenti:

Diabete di Tipo 1
Patologia a genesi autoimmune, caratterizzata dalla distruzione progressiva delle cellule β pancreatiche. Comporta una carenza assoluta di insulina e richiede terapia insulinica sostitutiva per tutta la vita.

Diabete di Tipo 2
Forma più diffusa a livello mondiale, associata prevalentemente a insulino-resistenza e deficit relativo di secrezione insulinica. È frequentemente correlata a fattori di rischio modificabili quali elevato indice di massa corporea (BMI), sedentarietà e abitudini alimentari scorrette.

Diabete Gestazionale
Condizione di alterata tolleranza al glucosio diagnosticata per la prima volta durante la gravidanza. Richiede monitoraggio e gestione attenta per prevenire complicanze materno-fetali.

1.4 Complicanze e Gestione a Lungo Termine

L'iperglicemia cronica rappresenta un fattore di danno sistemico progressivo. Se non adeguatamente controllata, può determinare complicanze a carico di diversi organi e apparati, tra cui:

- sistema cardiovascolare (malattia coronarica, ictus);
- rene (nefropatia diabetica);
- retina (retinopatia diabetica);
- sistema nervoso periferico (neuropatia diabetica).

Tuttavia, una diagnosi precoce e un controllo metabolico adeguato consentono di ridurre significativamente il rischio di complicanze. La gestione moderna del diabete si basa su:

- monitoraggio periodico della glicemia e dell'emoglobina glicata (HbA1c);
- controllo dei fattori di rischio cardiovascolare (pressione arteriosa, profilo lipidico);
- interventi personalizzati su alimentazione, attività fisica e terapia farmacologica.

In questo scenario, l'integrazione tra monitoraggio clinico e strumenti quantitativi di analisi dei dati può rappresentare un supporto strategico per una medicina sempre più orientata alla prevenzione e alla personalizzazione del trattamento.

---

2. Obiettivi del Progetto e Variabili di studio

Il presente progetto nasce dall'esigenza di tradurre la complessità clinica del diabete mellito in un modello matematico-statistico in grado di fornire indicazioni predittive sullo stato metabolico dei pazienti. L'approccio adottato mira a identificare e quantificare le relazioni tra i principali fattori di rischio e il controllo glicemico nel medio-lungo periodo, attraverso una modellazione multivariata.

2.1 Definizione dell'Obiettivo Scientifico

L'obiettivo primario dello studio è la costruzione di un modello di regressione lineare multipla (MLR), finalizzato alla stima di una variabile dipendente a partire da un insieme strutturato di variabili indipendenti (predittori).

Tale approccio consente di:

- quantificare il contributo marginale di ciascun fattore clinico o demografico;
- valutare l'interazione tra più dimensioni del rischio metabolico;
- stimare in termini numerici l'impatto complessivo dei predittori sull'andamento della patologia.

2.2 La Variabile di Risposta: Glicoemoglobina (HbA1c)

A differenza dei test glicemici istantanei, che riflettono la concentrazione di glucosio ematico al momento del prelievo, è stata selezionata come variabile target la glicoemoglobina (HbA1c), parametro espresso in percentuale che rappresenta la media delle glicemie degli ultimi 60–90 giorni.

La scelta dell'HbA1c è motivata da tre criteri principali:

Stabilità temporale
Fornisce una misura integrata del controllo glicemico nel tempo, attenuando l'effetto delle fluttuazioni acute legate a pasti, stress o variazioni circadiane.

Valore diagnostico
Rappresenta il parametro gold standard in ambito clinico per la diagnosi e il monitoraggio del Diabete Mellito, nonché per la valutazione del rischio di complicanze micro- e macrovascolari.

Affidabilità statistica
Presenta generalmente una variabilità inferiore rispetto alla glicemia a digiuno, contribuendo a rendere il modello di regressione più robusto e meno sensibile a outlier isolati.

Valori di riferimento clinici

I principali intervalli interpretativi dell'HbA1c sono:

- **Range di normalità:** circa 5%–6% (limite fisiologico inferiore ≈ 4%).
- **Prediabete:** 5,7% – 6,4%.
- **Diabete mellito:** ≥ 6,5% (criterio diagnostico).

- **Target terapeutico:** ≈ 7% nei pazienti in trattamento, come obiettivo di controllo metabolico.

- **Gravidanza:** valori soglia più stringenti (≈ 5,4% nei primi due trimestri), per garantire un adeguato monitoraggio materno-fetale.

Emoglobina Glicata nel soggetto normale	
HbA1c (%)	Utilizzo
4.0	Limite inferiore in soggetti non diabetici
5.4	Limite superiore in gravidanza (1° e 2° trimestre
5 - 6	Valori normali nei soggetti sani
5.7 – 6.5	Diagnosi di prediabete
6.5	Diagnosi di diabete
7	Obiettivo terapeutico primario

2.3 Selezione delle Variabili Esplicative (Predittori)

Le variabili indipendenti sono state selezionate sulla base della plausibilità biologica e dell'evidenza epidemiologica, includendo differenti dimensioni del rischio metabolico:

Fattori demografici

- Età

- Sesso

Variabili necessarie per contestualizzare l'invecchiamento fisiologico e le differenze biologiche nella regolazione metabolica.

Indicatori antropometrici

- Indice di Massa Corporea (BMI)
  Parametro chiave per la valutazione dell'obesità e della sua associazione con l'insulino-resistenza.

Biomarker clinici

- Glicemia a digiuno

- Insulina ematica
- Colesterolo totale

Questi indicatori forniscono una visione integrata del profilo glicemico e lipidico del soggetto.

Stile di vita

- Frequenza dell'attività fisica (LTPA)
  Inclusa come variabile potenzialmente protettiva, in grado di influenzare positivamente la sensibilità insulinica e il controllo metabolico.

2.4 Approfondimento su la glicoemoglobina e sul legame con l'indice di massa corporea

L'emoglobina glicata (HbA1c) e l'indice di massa corporea (BMI) rappresentano indicatori centrali nella stratificazione del rischio diabetico, anche in popolazioni non ancora affette da diabete conclamato.

Uno studio condotto presso la Università di Glasgow ha analizzato 1.620 soggetti non diabetici affetti da insufficienza cardiaca cronica. Dopo un follow-up medio di 2,8 anni, sono stati osservati 126 nuovi casi di diabete, evidenziando un'incidenza compresa tra 21 e 28 casi per 1.000 individui, superiore rispetto ai 16,8 casi per 1.000 osservati nella popolazione senza patologia cardiaca.

L'analisi multivariata ha identificato HbA1c e BMI come i predittori indipendenti più significativi per l'insorgenza del diabete di tipo 2. In particolare, incrementi progressivi di entrambi i parametri risultavano associati a un aumento proporzionale del rischio di sviluppare la patologia.

Queste evidenze rafforzano il razionale metodologico del presente studio, giustificando l'inclusione simultanea di HbA1c e BMI all'interno di un modello multivariato finalizzato alla stima del rischio metabolico e alla previsione dello stato glicemico.

---

3. Selezione delle Variabili e Data Engineering (Python)

La qualità e l'affidabilità di un modello statistico dipendono in modo sostanziale dalla qualità dei dati in ingresso. In questa fase è stata implementata una pipeline di data processing in linguaggio Python, con l'obiettivo di trasformare dataset grezzi e strutturalmente frammentati in un'unica base dati coerente e pronta per l'analisi statistica.

Sono stati utilizzati i database pubblici della piattaforma NHANES (National Health and Nutrition Examination Survey), relativi al ciclo di rilevazione agosto 2021 – agosto 2023.

3.1 Integrazione dei Flussi di Dati

La principale criticità metodologica è derivata dalla struttura del database NHANES, in cui le informazioni cliniche e demografiche sono distribuite su file distinti per dominio (ad esempio: dati demografici, esami di laboratorio, misurazioni antropometriche, questionari comportamentali).

Attraverso lo script *process_nhanes.py* è stata effettuata:

- la selezione delle variabili rilevanti per l'analisi;
- l'armonizzazione dei formati;
- il merging dei dataset mediante la chiave primaria **SEQN**, identificativo univoco del partecipante.

L'operazione di integrazione ha garantito la corrispondenza univoca dei record e la conservazione dell'integrità informativa per ciascun soggetto incluso nell'analisi.

3.2 Definizione del Dataset Analitico

Sulla base dell'evidenza riportata in letteratura in ambito diabetologico e metabolico, sono state selezionate le seguenti variabili:

Variabile target (Y)

- **LBXGH (Glicoemoglobina – HbA1c)**: scelta come outcome principale per la sua stabilità e per la capacità di riflettere il controllo glicemico medio nel medio-lungo periodo.

Covariate demografiche (X)

- **RIDAGEYR (Età)**: inclusa per controllare l'effetto dell'invecchiamento sui processi metabolici.
- **RIAGENDR (Genere)**: inserita per tenere conto di eventuali differenze biologiche e ormonali.

Covariate cliniche e metaboliche (X)

- **BMXBMI (Indice di Massa Corporea)**: indicatore dello stato ponderale.
- **LBXGLU (Glicemia a digiuno)**: marker diretto del metabolismo glucidico.
- **LBXIN (Insulina ematica)**: proxy della funzionalità pancreatica e della sensibilità insulinica.
- **LBXTC (Colesterolo Totale)**: parametro associato al profilo metabolico complessivo.

La selezione delle covariate è stata guidata da criteri di plausibilità biologica e rilevanza clinica, al fine di costruire un modello coerente dal punto di vista fisiopatologico.

3.3 Normalizzazione dell'Attività Fisica (LTPA)

Una criticità specifica ha riguardato la variabile relativa all'attività fisica nel tempo libero (LTPA), registrata nel database con frequenze temporali eterogenee (giornaliera, settimanale, mensile o annuale).

Per garantire comparabilità tra soggetti, è stato implementato l'algoritmo *process_physical_activity*, finalizzato alla standardizzazione della metrica in termini di **frequenza settimanale (LTPA Weekly Frequency)**.

Le conversioni adottate sono state:

- **Frequenza giornaliera** → moltiplicazione per 7
- **Frequenza mensile** → divisione per 4.33 (numero medio di settimane per mese)
- **Frequenza annuale** → divisione per 52

Tale procedura ha consentito di ottenere una misura omogenea e direttamente confrontabile tra individui, riducendo la variabilità artificiale dovuta esclusivamente alla modalità di registrazione del dato.

```
def process_physical_activity(file_path):
    """
    Processa le variabili NHANES PAD790Q (Quantità) e PAD790U (Unità)
    per creare una frequenza settimanale standardizzata.
    """
    df = pd.read_csv(file_path)
    epsilon = 5.397605346934028e-79
    df['PAD790Q'] = df['PAD790Q'].replace({7777: np.nan, 9999: np.nan, epsilon:
np.nan})
    df['LTPA_Weekly_Freq'] = np.nan
    df['PAD790U'] = df['PAD790U'].astype(str)
    mask_day = df['PAD790U'].str.contains('D')
    df.loc[mask_day, 'LTPA_Weekly_Freq'] = df.loc[mask_day, 'PAD790Q'] * 7
    mask_week = df['PAD790U'].str.contains('W')
    df.loc[mask_week, 'LTPA_Weekly_Freq'] = df.loc[mask_week, 'PAD790Q']
    mask_month = df['PAD790U'].str.contains('M')
    df.loc[mask_month, 'LTPA_Weekly_Freq'] = df.loc[mask_month, 'PAD790Q'] / 4.33
    mask_year = df['PAD790U'].str.contains('Y')
    df.loc[mask_year, 'LTPA_Weekly_Freq'] = df.loc[mask_year, 'PAD790Q'] / 52
    return df
```

3.4 Pulizia dei Dati (Data Cleaning)

Al fine di garantire l'affidabilità delle stime e la correttezza delle operazioni matriciali alla base del modello di regressione lineare, è stata implementata una fase strutturata di pulizia e validazione dei dati.

Le procedure adottate sono state le seguenti:

Rimozione di valori anomali e codici non validi
Sono stati identificati e rimossi i codici convenzionali utilizzati nei database NHANES per indicare valori mancanti o non determinabili (ad esempio 7777, 9999 o codifiche analoghe), nonché eventuali artefatti numerici incompatibili con il range fisiologico delle variabili analizzate. Tale operazione ha prevenuto distorsioni nella distribuzione dei dati e nelle successive stime dei parametri.

Gestione dei dati mancanti (NaN)
È stata adottata una strategia di *complete case analysis*, escludendo dall'analisi i record contenenti valori mancanti in una o più variabili di interesse. Sebbene tale approccio comporti una riduzione della numerosità campionaria, esso consente di preservare la coerenza delle matrici di progetto (X) e di evitare problematiche nella stima dei coefficienti tramite il metodo dei minimi quadrati ordinari (OLS).

Filtraggio di coerenza per la variabile LTPA
Sono stati mantenuti esclusivamente i soggetti con una frequenza di attività fisica positiva e logicamente coerente, al fine di evitare ambiguità interpretative legate a valori nulli o incongruenti. Questa scelta metodologica ha permesso di focalizzare l'analisi sull'associazione tra livello di attività fisica e controllo glicemico, riducendo il rumore informativo derivante da registrazioni inconsistenti.

Nel complesso, tali procedure hanno contribuito a costruire un dataset analitico strutturalmente solido, statisticamente coerente e idoneo all'implementazione del modello predittivo.

```
        df_dataset_clean = df_dataset.dropna()
        df_dataset_clean =
df_dataset_clean[df_dataset_clean['LTPA_Weekly_Freq'] % 1 == 0]
```

3.5 Differenze tra prima e dopo la pulizia

A seguito delle procedure di pulizia e filtraggio descritte, la numerosità campionaria si è ridotta da 7.199 a 2.328 osservazioni complete. Tale riduzione riflette l'applicazione dei criteri di esclusione relativi a valori mancanti, codifiche non valide e condizioni di incoerenza nelle variabili selezionate.

Si procede ora con un'analisi descrittiva della distribuzione delle variabili incluse nel dataset finale, mediante la rappresentazione grafica tramite istogrammi. Questa fase consente di valutare la forma delle distribuzioni (simmetria, eventuale skewness, presenza di code o outlier), verificare l'assenza di anomalie residue e acquisire una comprensione preliminare delle caratteristiche statistiche dei predittori e della variabile target prima della modellazione.

3.5.1 Analisi delle distribuzioni - istogrammi

1. Glicoemoglobina (Variabile Target)

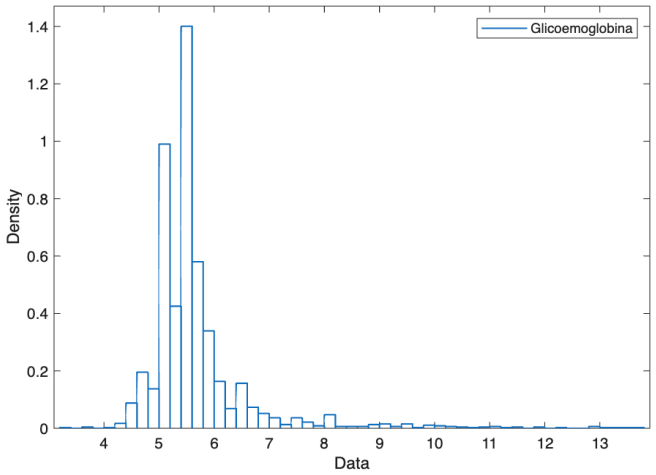

Descrizione: Rappresenta il fulcro del modello predittivo. La distribuzione è fortemente asimmetrica a destra (positive skewness).

Analisi Visiva: Si osserva un picco di densità molto elevato tra 5.4% e 5.6%, che corrisponde alla fascia di normalità. La lunga "coda" che si estende fino a valori di 13% identifica i soggetti con diabete scompensato.

Ruolo nel Modello: Essendo la variabile di risposta, la sua variabilità verrà spiegata dall'insieme dei predittori clinici.

2. Età (RIDAGEYR)

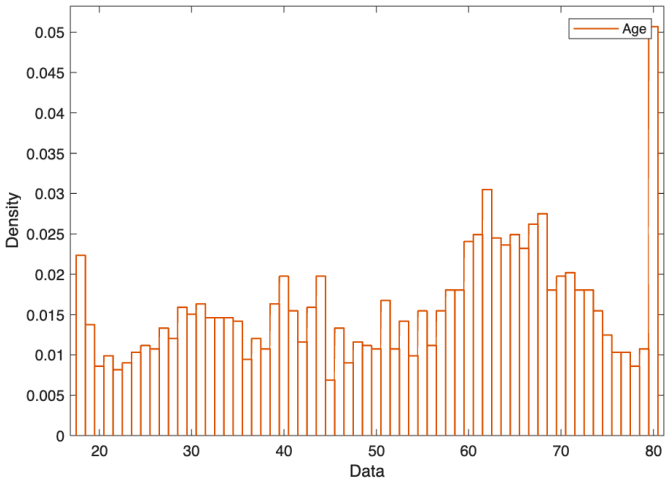

Descrizione: Distribuzione demografica del campione analizzato.

Analisi Visiva: Il grafico mostra una copertura pressoché uniforme per tutte le età adulte, con un accumulo finale sulla fascia dei 80 anni (probabilmente dovuto a un limite di codifica del database per proteggere la privacy).

Ruolo nel Modello: L'età è un fattore di rischio non modificabile critico, poiché il metabolismo tende a deteriorarsi con l'invecchiamento.

3. Genere (RIAGENDR)

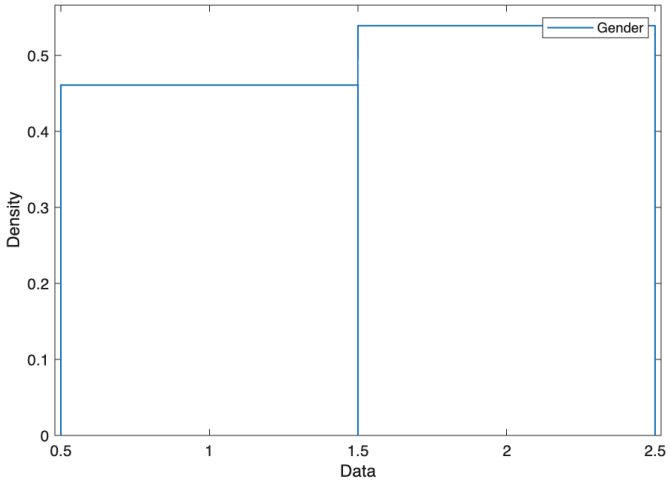

Descrizione: Variabile categorica binaria (1: Maschi, 2: Femmine).

Analisi Visiva: Il campione risulta estremamente equilibrato, con una densità vicina allo 0.5 per entrambe le categorie (leggera prevalenza della categoria 2).

Ruolo nel Modello: Permette di osservare se esistono differenze sistemiche nel controllo glicemico tra i due sessi.

4. Indice di Massa Corporea (BMI)

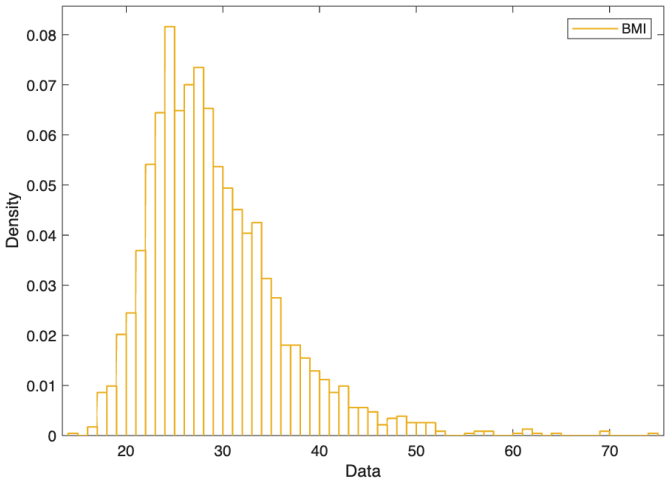

Descrizione: Misura antropometrica del grasso corporeo.

Analisi Visiva: La distribuzione è quasi "a campana", ma con una pendenza più dolce verso destra. Il picco è situato tra 25 e 28 (sovrappeso), con una coda che raggiunge valori di obesità grave (BMI > 50).

Ruolo nel Modello: Come discusso nel Capitolo 2, il BMI è il principale driver dell'infiammazione e dell'insulino-resistenza.

5. Glicemia a Digiuno (Fasting Plasma Glucose)

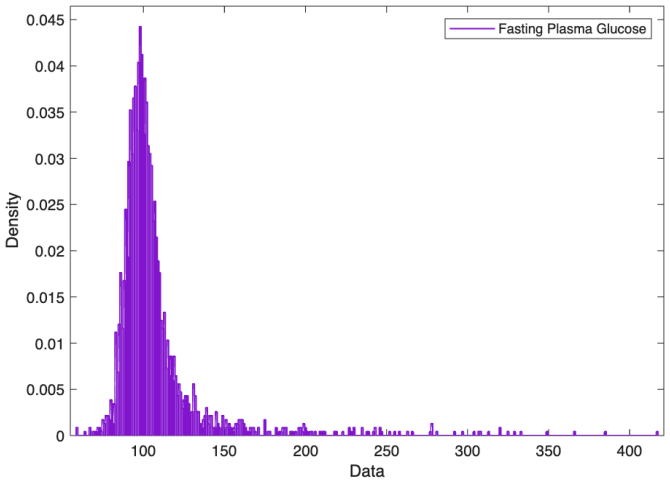

Descrizione: Livello di zucchero nel sangue dopo un periodo di digiuno.

Analisi Visiva: Presenta una densità altissima attorno ai 100 mg/dL. La coda destra è estremamente lunga, arrivando a toccare i 400 mg/dL, segno di iperglicemia acuta.

Ruolo nel Modello: È un predittore diretto della glicoemoglobina, poiché riflette lo stato glicemico immediato.

6. Insulina

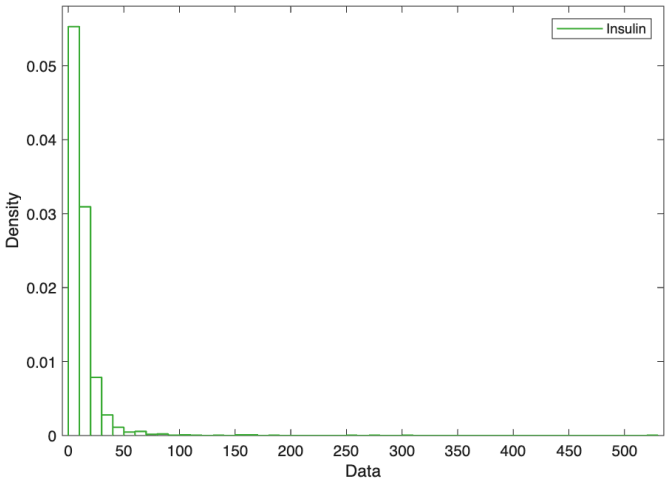

Descrizione: Livelli di ormone insulinico nel sangue.

Analisi Visiva: La distribuzione è "L-shaped" (fortemente asimmetrica). La stragrande maggioranza dei valori è molto bassa (vicina allo zero), mentre pochissimi casi presentano valori elevatissimi (oltre 500).

Ruolo nel Modello: Valori molto alti di insulina a digiuno sono indicatori precoci di insulino-resistenza, anche in presenza di glicemia ancora normale.

7. Frequenza Attività Fisica (LTPA Weekly Frequency)

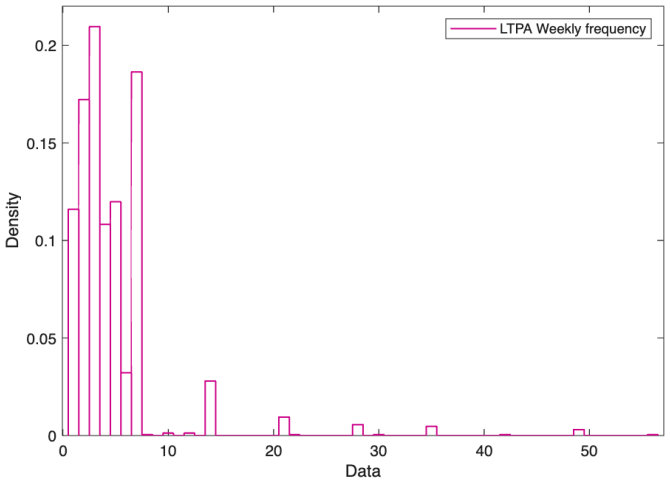

Descrizione: Numero di sessioni di attività fisica settimanale normalizzate.

Analisi Visiva: La distribuzione è frammentata. Si notano picchi sui valori interi (2, 3, 5 volte a settimana), mentre la densità cala drasticamente superate le 10 sessioni.

Ruolo nel Modello: Funge da variabile "protettiva". Ci aspettiamo che a un aumento della frequenza corrisponda una riduzione della glicoemoglobina.

8. Colesterolo Totale

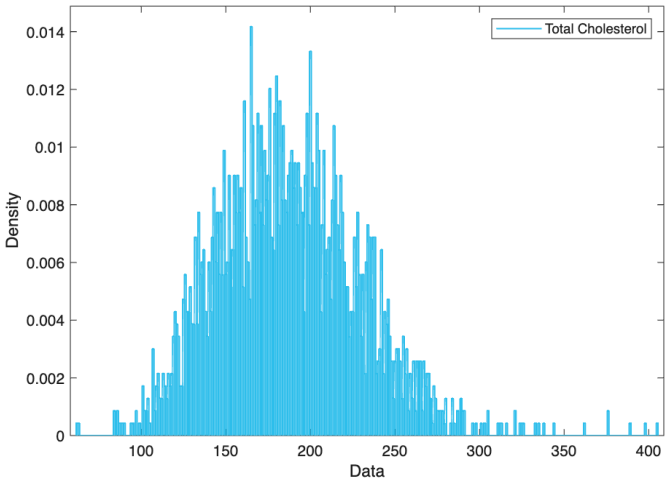

Descrizione: Misura della salute lipidica complessiva.

Analisi Visiva: Tra tutte le variabili, è quella che più si avvicina a una Distribuzione Normale (Gaussiana), con un centro attorno a 180-200 mg/dL.

Ruolo nel Modello: Serve a valutare il rischio cardiovascolare complessivo, che è spesso associato alle complicanze del diabete.

3.6 Matrice di Correlazione

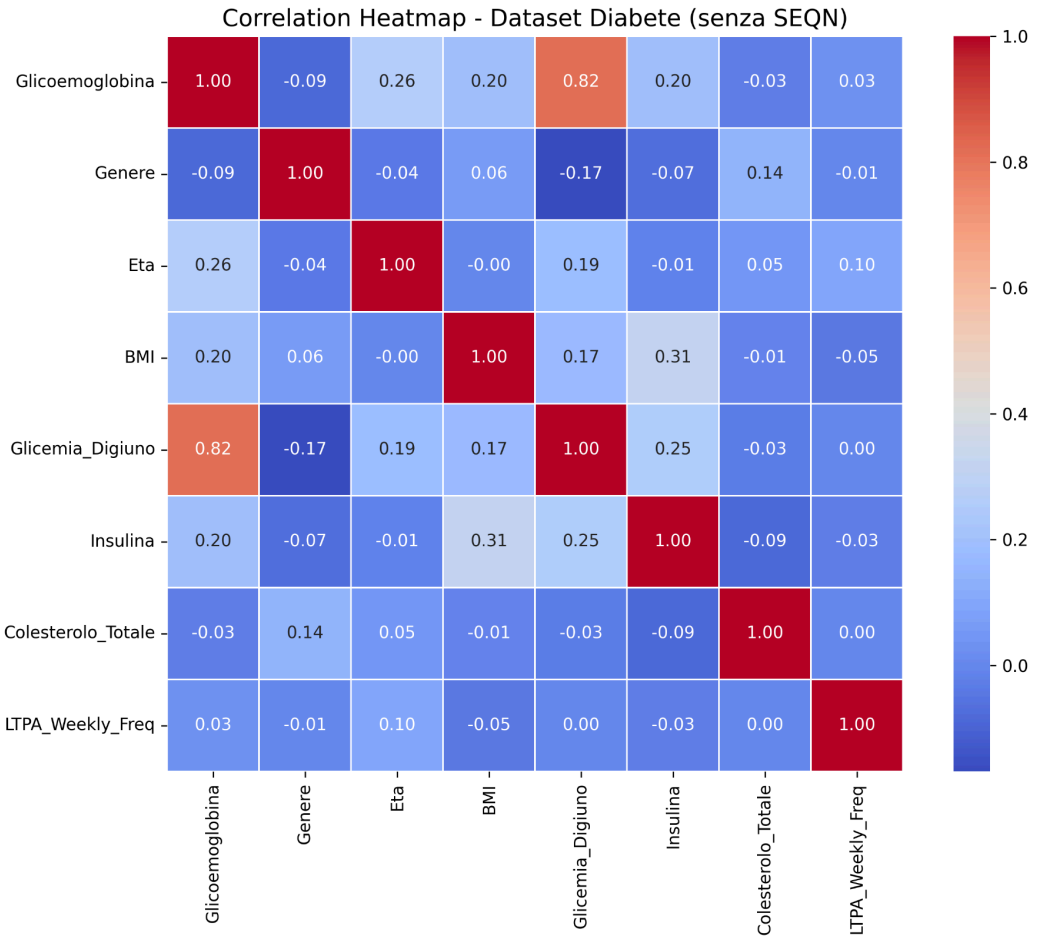

Al fine di valutare la consistenza delle relazioni lineari tra le variabili cliniche selezionate e di motivarne l'inclusione nel modello di regressione multipla, è stata calcolata la matrice di correlazione lineare di Pearson, successivamente rappresentata mediante heatmap per facilitarne l'interpretazione visiva. Tale analisi preliminare risulta propedeutica alla fase di modellazione, in quanto consente di identificare i predittori maggiormente associati alla variabile target, la glicoemoglobina (HbA1c), e di esaminare le relazioni intercorrenti tra le variabili esplicative.

Di seguito vengono discusse le evidenze principali emerse dall'analisi dei coefficienti di correlazione (r).

Correlazione dominante – Glicemia a Digiuno
L'associazione più marcata è stata osservata tra glicemia a digiuno e glicoemoglobina, con un coefficiente pari a r = 0.82. Tale valore indica una forte correlazione positiva, coerente con il razionale clinico secondo cui i livelli glicemici a breve termine sono strettamente connessi al controllo glicemico medio nel lungo periodo, di cui l'HbA1c rappresenta un indicatore consolidato.

Contributo delle variabili demografiche e antropometriche
L'età mostra una correlazione positiva moderata con l'HbA1c (r = 0.26), suggerendo un

incremento medio dei livelli di emoglobina glicata all'aumentare dell'età. Il BMI presenta una correlazione positiva più contenuta (r = 0.20) con la variabile target. Di interesse è inoltre la correlazione tra BMI e insulina (r = 0.31), che riflette un'associazione coerente con i meccanismi fisiopatologici dell'insulino-resistenza frequentemente osservati nei soggetti con eccesso ponderale.

Correlazioni deboli
Variabili quali genere (r = −0.09), colesterolo totale (r = −0.03) e frequenza di attività fisica settimanale (LTPA) (r = 0.03) presentano coefficienti prossimi allo zero, indicando una debole associazione lineare con l'HbA1c nel campione analizzato. Ciò non esclude un loro potenziale ruolo clinico, ma suggerisce che il contributo lineare diretto al modello potrebbe risultare limitato oppure mediato da interazioni o relazioni non lineari.

Relazioni tra predittori (inter-correlations)
La matrice evidenzia una correlazione positiva tra insulina e glicemia a digiuno (r = 0.25), compatibile con la risposta pancreatica a stati di alterazione glicemica. L'assenza di correlazioni estremamente elevate tra i predittori (valori prossimi a ±1) riduce il rischio di multicollinearità severa, supportando la stabilità delle stime dei coefficienti nella successiva regressione multipla.

In sintesi, l'analisi della matrice di correlazione fornisce un supporto statistico preliminare all'adozione di un approccio multivariato, evidenziando sia la rilevanza dei principali biomarker metabolici (glicemia, insulina, BMI) sia l'assenza di criticità strutturali tali da compromettere l'affidabilità del modello predittivo implementato in ambiente MATLAB.

---

4. Analisi Statistica e Modellazione (MATLAB)

La fase analitica, implementata mediante lo script *ProgettoMOTT.m*, si è focalizzata sulla quantificazione delle relazioni tra le variabili indipendenti e l'outcome, nonché sulla costruzione del modello predittivo.

4.1 Analisi delle Correlazioni

In una prima fase è stata condotta un'analisi esplorativa mediante il calcolo dei coefficienti di correlazione lineare di Pearson (r) tra ciascun predittore e i valori di glicoemoglobina (HbA1c), al fine di valutare l'intensità e la direzione delle associazioni lineari.

I risultati hanno evidenziato:

- **Correlazioni positive (r > 0):** Indice di Massa Corporea (BMI), glicemia a digiuno ed età mostrano un'associazione diretta con i livelli di HbA1c, indicando che all'aumentare di tali variabili si osserva, in media, un incremento del valore dell'outcome. Questo andamento è coerente con il profilo di rischio metabolico noto in letteratura.

- **Correlazioni negative (r < 0):** Il livello di attività fisica nel tempo libero (LTPA) presenta un'associazione inversa con la glicoemoglobina, suggerendo un potenziale effetto protettivo rispetto al peggioramento del controllo glicemico.

L'analisi delle correlazioni ha quindi fornito un primo riscontro quantitativo sulla coerenza biologica delle variabili selezionate, supportando la successiva inclusione delle stesse nel modello di regressione multipla.

4.2 Regressione Lineare Multipla e la "Trappola del P-Value"

Il modello predittivo è stato definito mediante una regressione lineare multipla (MLR), formalizzata dalla seguente equazione:

$$Y = \beta 0 + \beta 1X1 + \beta 2X2 + \cdots + \beta nXn + \varepsilon$$

Nelle fasi iniziali di addestramento, condotte sull'intero dataset disponibile, il modello globale ha evidenziato un p-value approssimativamente pari a zero al test F di significatività complessiva. Tale risultato indicava che l'insieme delle variabili esplicative contribuiva in modo statisticamente significativo alla spiegazione della variabilità della variabile dipendente, suggerendo l'esistenza di una relazione lineare non casuale tra predittori e outcome nel campione analizzato.

Tuttavia, questa valutazione era interamente basata su un'analisi *in-sample*, ossia effettuata sugli stessi dati utilizzati per stimare i parametri del modello. In questo contesto, un'elevata significatività statistica non implica necessariamente una reale capacità predittiva al di fuori del campione di addestramento. Al contrario, l'ottimo adattamento ai dati osservati può riflettere un fenomeno di overfitting, in cui il modello apprende non solo la struttura sottostante del segnale, ma anche componenti di rumore specifiche del dataset considerato. Di conseguenza, il p-value del test F, pur confermando la validità statistica delle associazioni nel campione, non garantiva la robustezza né la trasferibilità del modello a nuovi pazienti.

Alla luce di tali considerazioni, si è resa necessaria l'adozione di una strategia di validazione più rigorosa, finalizzata a stimare in modo più realistico le performance predittive del modello su dati indipendenti e a valutarne la reale capacità di generalizzazione in un contesto clinico.

---

5. Validazione del Modello Predittivo

Al fine di valutare in modo realistico la capacità di generalizzazione del modello, è stato implementato un protocollo di validazione *out-of-sample*, volto a stimarne le performance su dati non utilizzati nella fase di addestramento.

5.1 Strategia di Suddivisione (Holdout 80/20)

Il dataset è stato suddiviso casualmente secondo la strategia di *holdout*:

- **Training Set (80%)**: utilizzato per la stima dei coefficienti β\betaβ mediante regressione lineare multipla.

- **Test Set (20%)**: mantenuto completamente indipendente e non impiegato durante l'addestramento, con l'obiettivo di simulare l'arrivo di nuovi pazienti in un contesto clinico reale e valutare in modo oggettivo la capacità predittiva del modello.

Questa procedura consente di evitare stime ottimistiche delle performance, tipiche delle valutazioni condotte esclusivamente *in-sample*.

5.2 Valutazione Visiva (Scatter Plot) e Metriche Quantitative

Per analizzare le prestazioni predittive sul Test Set, è stato innanzitutto generato uno *scatter plot* dei valori osservati rispetto ai valori predetti. La distribuzione dei punti, che come si vede, si trova in prossimità della bisettrice del primo e terzo quadrante $(y = x)$ ha fornito un riscontro visivo dell'accordo tra stime e osservazioni reali, in assenza di pattern sistematici di sovra- o sottostima.

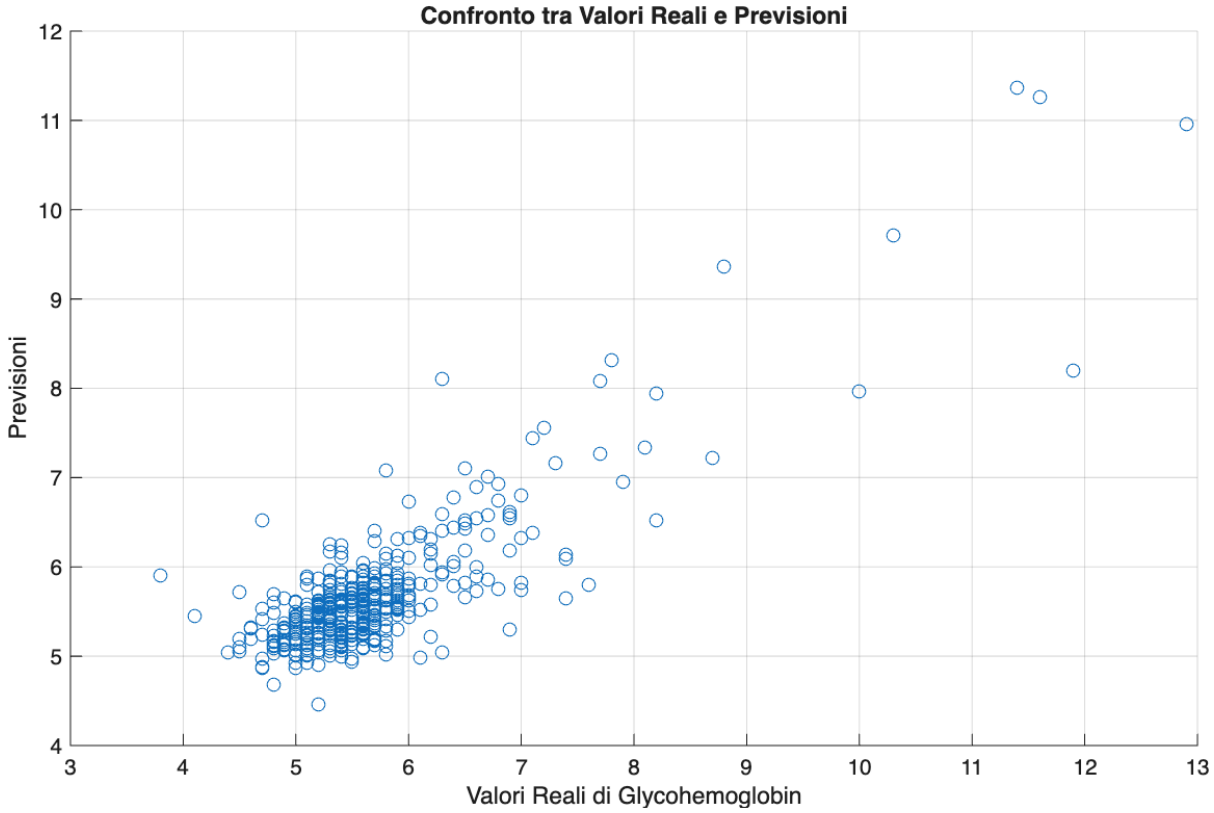

L'accuratezza del modello è stata quindi quantificata mediante indicatori oggettivi:

- **RMSE (Root Mean Squared Error)**: misura della deviazione standard dei residui sul Test Set, espressa nelle stesse unità dell'outcome (HbA1c). Tale metrica fornisce una stima dell'errore medio di previsione e consente un'interpretazione clinicamente immediata dell'entità dello scostamento.

- **R^2 out-of-sample**: calcolato sul Test Set come

$$R2 = 1 - SST/SSE$$

dove *SSE* rappresenta la somma dei quadrati degli errori di previsione e *SST* la somma totale dei quadrati rispetto alla media osservata nel Test Set. Un valore positivo e sostanziale di R^2 indica che il modello è in grado di spiegare una quota significativa della variabilità della glicoemoglobina anche su pazienti non inclusi nella fase di addestramento, confermando la capacità di generalizzazione e la potenziale rilevanza clinica delle variabili selezionate.

---

6. Conclusioni

La gestione moderna del Diabete Mellito non può essere ricondotta esclusivamente alla terapia farmacologica, ma richiede un approccio multidisciplinare che integri monitoraggio clinico, interventi sullo stile di vita e strumenti quantitativi di supporto decisionale. In questo contesto, l'analisi statistica e le tecniche di modellazione predittiva rappresentano un valido complemento alla pratica clinica.

Il presente progetto ha dimostrato come, a partire da dati clinici strutturati e opportunamente preprocessati, sia possibile costruire un modello di regressione lineare multipla in grado di stimare il controllo glicemico nel medio-lungo periodo. La modellazione congiunta di biomarker misurabili (quali glicemia e insulina) e fattori di rischio modificabili (come indice di massa corporea e livello di attività fisica) ha consentito di quantificare in modo oggettivo il contributo di ciascuna variabile all'andamento dell'HbA1c.

I risultati ottenuti suggeriscono che l'integrazione tra dati clinici e strumenti di machine learning può favorire una stratificazione più accurata del rischio metabolico e supportare interventi preventivi mirati. In particolare, l'identificazione precoce di profili a maggior rischio potrebbe consentire azioni tempestive sui determinanti modificabili della patologia, con potenziali benefici in termini di riduzione delle complicanze croniche, miglioramento della qualità della vita e ottimizzazione delle risorse sanitarie.

Pur nei limiti metodologici intrinseci (riduzione del campione a seguito della *complete case analysis*, assunzione di linearità del modello), il lavoro fornisce un esempio concreto di applicazione dell'analisi quantitativa in ambito biomedico, evidenziando come la traduzione della complessità clinica in modelli matematici possa contribuire a una medicina sempre più data-driven.